
# Topic Modeling Of Arabic Articles

**Roy El Tenn** 

Ahmad Al Sharbaji

Capstone Project Machine Learning Certification



## OUTLINE





- Introduction
- Motivation & Problem
   Definition

#### Introduction

- Aims to build a model that can detect topics of texts in the Arabic language.
- Analyze the document data and predict one or more labels.

MLC: Multi-Label Classification is the problem of classifying instances into one or more classes where one or multiple labels can be assigned for each instance

	Belarus In Turmoil	COVID- 19	How the Karabakh conflict is transforming regional politics	Myanmar Coup	Myanmar Election 2020	NewsFrames	آداب	أخبار جيدة	أخبار عاجلة	أديان	أصالة	أفكار	أقلام	احتجاج	الأصوات الصاعدة	الأعراق والأجناس	الألعاب الأولمبية	الإعلام والصحافة	الاقتصاد والأعمال	الجس	الدعم الإنساني	النساء والنوع	النشاط الرقمي	الهجرة والنزوح	انتخابات
0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
2	0	0	0	0	0	0	0	0	1	0	0	0	0	1	0	0	0	0	0	0	0	0	1	0	1
3	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	1	0
4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
4964	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0
4965	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
4966	0	0	0	0	0	0	0	0	0	0	1	0	0	0	1	0	0	0	0	0	0	0	0	0	0
4967	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	1	0	0

#### **Problem Definition**

Detect topics of text in the Arabic Language

قدمت مدونة شينجيانج أقصى غرب الصين مدينة كاراماي في شينجيانج، على أنها أغنى مدينة في وفقاً لأحدث 2012الصين لعام يعود الفضل في ثروة .بحث المدينة المنشأة حديثاً إلى البترول









## Previous Work

#### State of Art




Fig. 1. Text Classification Taxonomy

#### **Previous Solutions**

- Few studies have investigated multi-label text classification for the Arabic language.
- Most of these studies have focused mainly on flat classification and have neglected the hierarchical structure.

ahmed et al: transform MLC into single label classification using MEKA tool to implement LP, BR approach.



Using SVM as a base classifier with the LP method achieved the best ML-accuracy with 71%.

Shehab et al. : Three multi-label classifiers were adapted to deal with MLC problems: random forest (RF), DT, and k-NN with k = 5 (5-NN).



The DT classifier achieved a better performance than the RF and 5-NN classifiers.

#### **Previous Solutions**

Zayed et al. hierarchical multi-label classification model to address HMC problems in the Arabic language which used the HOMER algorithm.




Achieve more effective predictive performance compared to the BR-NB classifier, which simply classified each label independently.

HMATC model was implemented based on the HOMER algorithm, which was optimized by employing LP-SVM classifier and balanced k-means algorithm with eight clusters in order to improve hierarchical classification outcomes.



HMATC model outperformed all the evaluated models in terms of computational cost.

#### • Previous Solutions



Data Preprocessing

- Collecting Data
- EDA

## **Data Preprocessing**


- Data Provided by TARJAMA team
- Text & Label Separated

- Merge the Data
- Removed the unused columns
- Drop the Null Text rows

1	Belarus In Turmoil	COVID- 19	How the Karabakh conflict is transforming regional politics	Myanmar Coup	Myanmar Election 2020	NewsFrames	آداب	أخبار جيدة	أخبار عاجلة	أديان		أفكار	أقلام	احتجاج	الأصوات الصاعدة	الأعراق والأجتاس	الألعاب الأولمبية	الإعلام والصحافة	الاقتصاد والأعمال	العس	الدعم الإنساني	النساء والنوع	النشاط الرقمي	الهجرة والنزوح	انتخابات	يود كاست الأصوات العالمية
لخصت القدادة الجامايكية جودي أن ماكميلان سيرة	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
في الأسبوع الماضي، ثار الجمهور لليجة لتصريحات	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
جميع الروابط] تؤدي للفريسية ما لم ينص على خلاف	0	0	0	0	0	0	0	0	1	0	0	0	0	1	0	0	0	0	0	0	0	0	1	0	1	0
مواطنو أمريكا اللاتينية يحبون السفر. يمكن أن ي	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	1	0	0
اليوم مر عام منذ أن تم اعتقال وسجن باسل خرطبيل	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0

## **Data Preprocessing**


Used ArabertPreprocessor function from arabert.preprocess



Increased the amount of data by using ML SMOTE

#### Some function:

- strip\_tashkeel: bool = True
- strip\_tatweel: bool = True
- insert\_white\_spaces
- strip\_ shadda : bool = True




### **Data Preprocessing**

Split our data into train 80 % & test 20 %

```
!mkdir data
train_AJGT.to_csv("data/train.csv",index=False,columns=train_AJGT.columns,sep='\t',header=True)
test_AJGT.to_csv("data/test.csv",index=False,columns=test_AJGT.columns,sep='\t',header=True)
```

- Max Length of Training data is 3274
- Max Length of Testing Data is 2930




	support	itemsets
0	0.186154	(احتجاج)
1	0.125176	(الإعلام والصدافة)
2	0.197827	(النشاط الرؤمي)
3	0.125176	(يَقَارِهُ)
4	0.169853	(حروب وبزاعات)
5	0.184142	(حرية التعبير)
6	0.276313	(حقوق الإنسان)
7	0.129000	(حكم)
8	0.290199	(سياسة)
9	0.101429	(شباب)
10	0.750453	(صحافة المواطن)
11	0.102838	(علاقات دولية)
12	0.147515	(فنون وثقافة)
13	0.118334	(سياسة, احتجاج)
14	0.163011	(احتجاج, صحافة المواطن)
15	0.152948	(النشاط الرقمي, صحافة المواطن)
16	0.130409	(صحافة المواطن, حروب ونزاعات)
17	0.112497	(حقوق الإنسان, حرية التحبير)
18	0.146911	(صدافة المواطن, حرية التعبير)
19	0.109076	(سياسة, حقوق الإنسان)
20	0.232240	(حقوق الإنسان, صحافة المواطن)
21	0.100020	(صحافة المواطن, حكم)

# Solution & Results


- Proposed Method
- Results

## **Proposed Method**




• Transformer architecture is an encoder-decoder network that uses self-attention on the encoder side and attention on the decoder side.


- BERT is basically an Encoder stack of transformer architecture.
- AraBERT is an Arabic pretrained language model based on Google's BERT architecture



## Results

	TFIDF	
	Random Forest	SVM
Exact Match Ratio	0.75	0.24
F1-Score Weighted	0.87	0.64
F1-Score Samples	0.83	0.63
Hamming Loss	0.03	0.08






- Conclusion
- Future Work

## **Future Work**



- > Try To implement hierarchical Solution.
- > Results based on Arabert.
- > Tunning the model.



ANY Questions?



Thank You...